


Predykcja wystąpienia wstrząsów za pomocą symulacji Monte Carlo



<https://www.sciencedirect.com/topics/nursing-and-health-professions/monte-carlo-method>

Zespół Isentropix

Aleksander Kudyba, Bartosz Szych


Łańcuch Markowa

Dla wielu predykcyjnych zadań, gdzie trudno jest powiązać ze sobą w prosty sposób występujące po sobie zjawiska, wykorzystuje się symulacje za pomocą łańcuchów Markowa, np. przewidywanie pogody lub zachowania rynków finansowych.

Podstawą do przeprowadzenia symulacji jest skonstruowanie odpowiedniej macierzy przejścia (ang. transition matrix), czyli prawdopodobieństw wszystkich zmian stanów w naszym łańcuchu.

$$P = \begin{bmatrix} 0.9 & 0.075 & 0.025 \\ 0.15 & 0.8 & 0.05 \\ 0.25 & 0.25 & 0.5 \end{bmatrix}.$$

https://en.wikipedia.org/wiki/Examples_of_Markov_chains



Przykładowe macierz i diagram dla stanów na giełdzie.

Macierz przejścia dla jednego cyklu

Żeby wygenerować prawdopodobieństwa przejść między stanami, w tym wypadku brakiem wstrząsów oraz wstrząsami w 3 różnych regionach, przeanalizowano dane zliczając wszystkie możliwe przypadki za pomocą skryptu w Pythonie.

W przypadku naszego algorytmu korzystamy z wariantu łańcucha Markowa z dyskretyzacją czasu, stąd dodatkowo z całego zestawu danych został dobrany interwał czasowy, w którym realizowany jest jeden cykl. Interwał Δt to uśredniona wartość czasu pomiędzy następującymi po sobie pomiarami.

Δt wyniósł w tym wypadku 30 min.

W celu zademonstrowania działania algorytmu została dobrana przestrzeń stanów składająca się z:

- Brak znaczących wstrząsów (dla braku współrzędnych wstrząsów)
- Wstrząsy w rejonach odpowiednio: RG – *Rudna Główna*, RZ – *Rudna Zachodnia* i RP – *Rudna Północna*

0.9165	0.0478	0.025	0.0107
0.2729	0.6951	0.0227	0.0093
0.5518	0.0545	0.3937	0
0.6849	0.0383	0.0306	0.2462

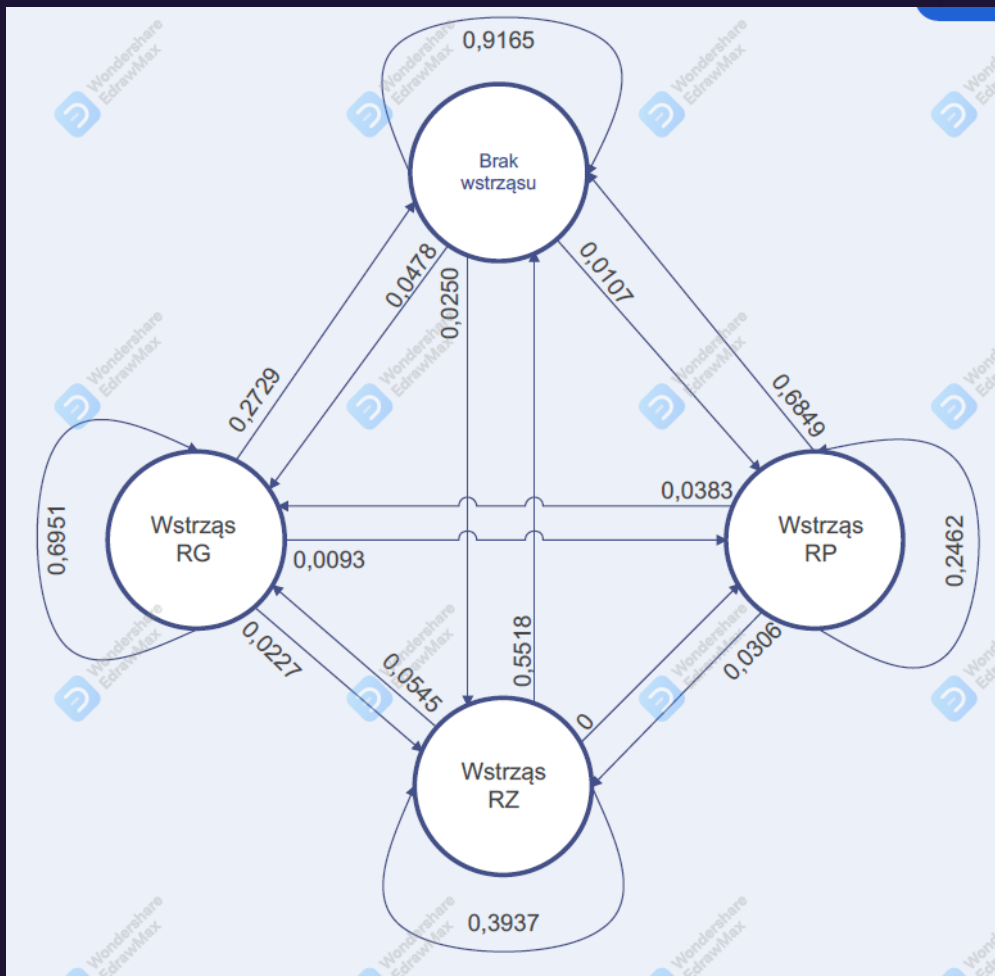



Diagram dla przeprowadzanej symulacji



Przykładowe rozwinięcie diagramu dla innych przypadków

Wstęp do analizy wyników

Zakres predykcji:


Prezentowany model został zastosowany dla predykcji wstrząsów w przedziale jednego roku, by zachować odpowiedni stosunek do analizowanych danych historycznych. Zakres ten odpowiada więc $17520 \Delta t$. Można więc założyć, że przewidujemy częstotliwości wstrząsów na następny rok.

Dla tego przedziału przeprowadzamy więc analizę zbieżności naszych wyników.

Prawo wielkich liczb

Symulacje Monte Carlo w swoim podstawowym założeniu opierają się na prawie wielkich liczb. W naszym przypadku prawo to gwarantuje nam zbieżność wyników dla pewnej liczby powtórzeń symulacji jednego roku.

https://pl.wikipedia.org/wiki/Prawo_wielkich_liczb




http://www.j-bradford-delong.net/movable_type/images2/cltheorem

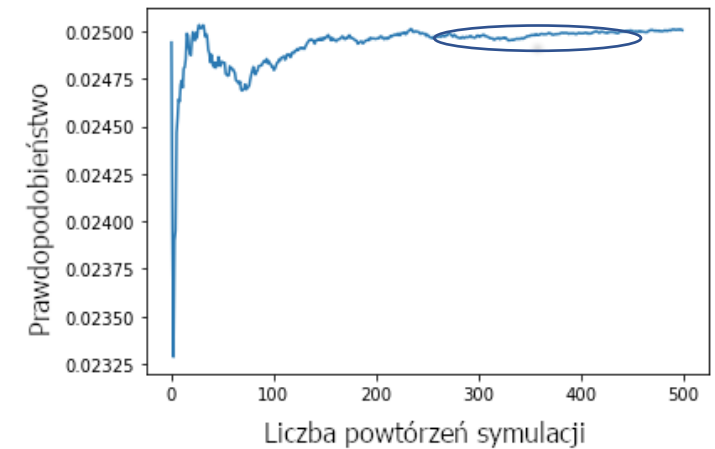
Wyniki i analiza zbieżności

Z wykresów można zauważyć, że zbieżność (plateau) dla symulacji jest uzyskiwana po około 400 powtórzeniach. Pozwala to zaoszczędzić czas w przypadku wykonywania tej symulacji dla innego zestawu danych, w przyszłości wykonując tylko tę określoną ilość powtórzeń i uzyskać dokładne wyniki.


Wykres prawdopodobieństwa wystąpienia wstrząsu w rejonie RP




Wykres prawdopodobieństwa wystąpienia wstrząsu w rejonie RZ



Wykres prawdopodobieństwa wystąpienia wstrząsu w rejonie RG




Wykres prawdopodobieństwa braku wstrząsu



Rozkład prawdopodobieństw w kwartałach

W przypadku rozkładów liczby wstrząsów na części przewidywanego okresu (tutaj z podziałem na kwartały) nie mamy do czynienia z dużymi fluktuacjami. W przypadku większej rozdzielczości fluktuacje powinny być większe, ale zaobserwowana mała korelacja między czasem a wstrząsami wydaje się być zgodna z rzeczywistością, a zatem stosunkowo prawdopodobną predykcją.



Możliwości wdrożenia i automatyzacja

Prezentowany model został zaprojektowany jako gotowy black box i może pracować dla nowo dostarczanych danych w takim formacie jak teraz. Ma też jednak potencjał do dalszych modyfikacji pod kątem analizy większej ilości miejsc wstrząsów oraz ich różnych energii.

Nawet dla prostego łańcucha Markowa skonstruowanego na potrzeby tego projektu można z niego wyciągnąć rozkład prawdopodobieństwa wstrząsów które mogą wystąpić w przyszłości, szanse na następujące po sobie serie wstrząsów itd..

Ponadto dokładność algorytmu może się tylko zwiększać wraz większą ilością danych do niego dostarczanych.

W literaturze predykcje trzęsień ziemi oparte o modele z wykorzystaniem łańcuchów Markova, osiągają dokładność 80%, a nawet 95%.

- <https://link.springer.com/content/pdf/10.1007/s00477-017-1457-1.pdf>
- <https://www.hindawi.com/journals/isrn/2014/632804/>
- [https://www.researchgate.net/publication/336958484_EARTHQUAKE_ANALYSIS_IN_EAST_JAVA_INDONESIA_BETWEEN_1960 - 2017_USING_MARKOV_CHAIN_MODEL](https://www.researchgate.net/publication/336958484_EARTHQUAKE_ANALYSIS_IN_EAST_JAVA_INDONESIA_BETWEEN_1960_-_2017_USING_MARKOV_CHAIN_MODEL)